

Učenje pozitivno definitnih neuralnih Lyapunov funkcija pomoću ICNN arhitekture za stabilne autoregresivne modele dinamike

Opis zadatka:

1. Upoznati se sa osnovama stabilnosti nelinearnih sistema i Lyapunov metodom (diskretno i/ili kontinuirano vreme), kao i vezom između Lyapunov funkcije i stabilnosti roll-out (autoregresivne) predikcije:
 - a) Khalil, H. K. *Nonlinear Systems* (3rd ed.). Prentice Hall (2002). Bibliografski zapis: cds.cern.ch/record/1173048.
 - b) (Opcionalno) Vidyasagar, M. *Nonlinear Systems Analysis* (2nd ed.). SIAM / Prentice-Hall (2002). SIAM opis: 10.1137/1.9780898719185.

Prethodni izvori su obavezni, ali literatura nije ograničena samo na njih.

2. Upoznati se sa ICNN (Input Convex Neural Networks) pristupom i načinom konstrukcije pozitivno definitnih skalarnih funkcija (npr. energija/Lyapunov) pomoću konveksnosti i kvadratnog donjeg ograničenja:
 - a) Amos, B., Xu, L. & Kolter, J. Z. *Input Convex Neural Networks*. ICML 2017 / preprint: arXiv:1609.07152.
 - b) Referentna implementacija ICNN: github.com/locuslab/icnn.
3. Upoznati se sa radovima koji eksplicitno koriste ICNN/Lyapunov konstrukcije za garantovanu ili empirijski stabilnu dinamiku i/ili autoregresivno predviđanje:
 - a) Manek, G. & Kolter, J. Z. *Learning Stable Deep Dynamics Models*. NeurIPS 2019 (PDF): papers.neurips.cc/.../stable-dynamics. Preprint: arXiv:2001.06116. Kod: github.com/locuslab/stable_dynamics.
 - b) Chang, Y.-C. et al. *Neural Lyapunov Control*. Preprint: arXiv:2005.00611.

4. Napraviti prezentaciju u kojoj se predstavlja:

- o definicija pozitivno definitne funkcije $V(x)$ i diskretni Lyapunov uslov za mapu $x_{t+1} = f(x_t)$ (i/ili za kontrolisani slučaj $x_{t+1} = f(x_t, u_t)$),
- o veza između autoregresivnog roll-out predviđanja i stabilnosti: akumulacija greške, eksponencijalna divergencija, potreba za strukturnim ograničenjima,
- o ICNN arhitektura: uslovi na težine koji obezbeđuju konveksnost u ulazu i tipične konstrukcije Lyapunov funkcije:

$$V_\phi(x) = \varphi_\phi(x) - \varphi_\phi(0) + \varepsilon \|x\|^2$$

gde je φ_ϕ ICNN skalarna funkcija konveksna u x ,

- o kriterijumi učenja: data-loss (npr. MSE nad x_{t+1} ili rollout MSE), plus Lyapunov penalizacija (opadanje V) i uslovi pozitivne definitnosti.

Prezentacija treba da sadrži i odgovarajuće matematičke izraze koji su navedeni u literaturi.

5. Pripremiti skup podataka (simulacije) za učenje dinamike i autoregresivnog predviđanja:

- odabrati najmanje **dva** sistema (preporuke): prigušeni oscilator / klatno (stabilan), Van der Pol (nelinearan), Lorenz (haotičan; opciono),
 - generisati početne uslove (rasponi x_0) i (ako se koristi) ulaze u_t ,
 - numerička integracija (referentno rešenje) na fiksnoj vremenskoj mreži $t_0, \dots, t_T$,
 - definisati ulaz/izlaz za autoregresivni model:
 - ulaz: x_t (i opciono istorija $x_{t-k:t}$, i/ili u_t),
 - izlaz: x_{t+1} (one-step) i evaluacija kroz roll-out do horizonta H .
6. Implementirati bazni autoregresivni model (bez stabilnosnih ograničenja) kao referencu:
- izabrati arhitekturu (preporuka): MLP za $x_{t+1} = f_\theta(x_t)$; opciono GRU/ResNet,
 - obuka sa one-step loss (MSE) i evaluacija na roll-out horizontima H ,
 - vizualizacije: trajektorije, greška kroz vreme, primeri divergiranja.
7. Implementirati ICNN mrežu za Lyapunov funkciju $V_\phi(x)$ i zajednički trening sa dinamičkim modelom:
- implementirati ICNN (konveksnost u x) i konstrukciju $V_\phi(x)$ sa $V_\phi(0) = 0$ i donjim kvadratnim ograničenjem $\varepsilon\|x\|^2$,
 - definisati Lyapunov penalizaciju (diskretni uslov opadanja) nad uzorcima iz trajektorija:

$$\mathcal{L}_{lya} = E \left[\max \left(0, V_\phi(\hat{x}_{t+1}) - V_\phi(x_t) + \alpha\|x_t\|^2 \right) \right],$$
 gde je $\hat{x}_{t+1} = f_\theta(x_t)$ (i/ili rollout predikcija),
 - ukupni loss: $\mathcal{L} = \mathcal{L}_{data} + \lambda\mathcal{L}_{lya} + \mu\mathcal{L}_{pd}$ (gde $\mathcal{L}_{pd}$ penalizuje kršenje pozitivne definitnosti ako se koristi),
 - stabilizacija obuke: scheduler, weight decay, gradient clipping; razmotriti trening u dve faze (one-step pretrening, zatim rollout fine-tuning).
8. Evaluirati model i analizirati stabilnost autoregresivne predikcije:
- metrike predikcije: RMSE/MSE kroz vreme, greška po horizontima, maksimalna greška u vremenu (worst-case),
 - metrike stabilnosti: boundedness (da li trajektorija ostaje ograničena), učestalost ispunjenja Lyapunov uslova (V opada), brzina rasta greške u roll-out,
 - generalizacija: test na početnim uslovima van trening opsega; duži horizont H ; (opciono) drugačiji režimi parametara sistema,
 - poređenje sa bar jednom baznom metodom:
 - bazni MLP/GRU bez stabilnosnog regularizatora,
 - opciono metoda iz Manek & Kolter (stable dynamics) ili contracting RNN kao referenca.
9. Napisati uputstvo za korišćenje raspoloživog koda (generisanje podataka, obuka, test, vizualizacija), povezati arhitekturu iz prezentacije sa konkretnim klasama/funkcijama u implementaciji i obavezno navesti verziju koda (tag/commit hash).

10. Napisati finalni izveštaj koji ima standardnu strukturu naučnog rada, i to:
- Uvod – motivacija: zašto autoregresivni modeli divergiraju i zašto su PD/Lyapunov ograničenja korisna.
 - Metode i materijali – opis dinamike, opis ICNN i konstrukcije $V(x)$, protokol obuke i testiranja (one-step i roll-out).
 - Rezultati i diskusija – performanse, stabilnost, analiza grešaka i ograničenja; ablation po λ i izboru horizonta.
 - Zaključak – najvažniji nalazi i predlozi za nastavak (kontrakcioni metriki, kontrolisani sistemi, veće dimenzije, formalna verifikacija).

Rezultat ovog zadatka treba da bude:

1. prezentacija o Lyapunov stabilnosti, ICNN konstrukciji pozitivno definitne funkcije i protokolu obuke/testiranja autoregresivnog modela
2. uputstvo za upotrebu (generisanje podataka, obuka, test, vizualizacija), koje povezuje arhitekturu i praktičnu implementaciju, uz navođenje verzije koda
3. finalni izveštaj
4. prateći kod koji je iskorišćen za generisanje podataka i implementaciju/obuku autoregresivnog modela i ICNN Lyapunov mreže (plus skripte za evaluaciju i vizualizaciju)